实时主动数据仓库的 4 种数据集成方式：

数据整合：用 ETL 把多数据源数据物理归集到数据仓库，是批量加载式的物理集中。

数据联邦：建统一逻辑视图（物理数据仍分散），按需实时从各数据源取数，适合实时 / 低成本场景。

数据传播：数据在多应用间传递（比如企业应用集成里的消息交互）。

混合方式：通用数据用整合，特定数据用联邦。

Kafka Topic（主题）是 Kafka 中消息的分类标识：

每条消息会归到一个 Topic 下，不同 Topic 的消息物理分开存储。

逻辑上，一个 Topic 的消息可存在多个 Broker（Kafka 节点），但用户只需指定 Topic，就能生产 / 消费消息，不用关心具体存储位置。

用 Kettle 实现数据排序的步骤：

建转换：打开 Kettle，新建一个转换。

加输入步骤：在转换里添加输入步骤（如文本 / 数据库输入），配置数据源。

加排序步骤：添加 “排序” 步骤，配置排序字段、顺序（升 / 降序）。

连步骤：拖拽连接输入和排序步骤，设置字段映射。

加输出步骤：添加输出步骤（如文本 / 数据库输出），配置目标位置。

运行转换：保存后运行，完成排序并输出结果

数据脱敏中 “保持业务规则的关联性”，是指脱敏后数据的关联关系、业务语义不被破坏：

比如主外键的关联、字段间的业务逻辑要保持一致；

对敏感数据（如账户类信息），需保证其关联的主体信息、行为信息的一致性

典型数据仓库的 4 个组成部分及含义：

数据源：数据仓库的基础，含企业内部业务 / 文档数据、外部法规 / 市场 / 竞品等数据。

数据存储和管理：核心部分，通过 ETL 将数据按主题重组存储，管理元数据（字典、规则等）及数据安全、备份等。

OLAP 服务器：将数据按多维模型重组，支持多维度、多角度分析数据规律。

前端工具和应用：包括查询、报表、分析、挖掘工具及各类应用系统。

在 Scrapy 中，通常一个 Spider 只针对一个网网站进行抓取，以避免不必要的请求和可能的反爬虫策略触发。：

Scrapy 是纯 Python 实现的异步爬虫框架（基于 Twisted），跨系统运行，特点是快、易扩展、易用；可本地 / 云端部署，用于数据采集、挖掘、监测等；支持自定义，同时 Python 还有 Crawley、Beautiful Soup 等其他爬虫框架。

用 Kettle 将本地文件加载到 HDFS 的步骤：

建转换：打开 Kettle，新建一个转换。

加文本输入步骤：添加 “文本文件输入”，配置本地文件路径、分隔符、编码等。

加 Hadoop 输出步骤：添加 “Had oop 文件输出”，配置 Hadoop 集群连接、目标 HDFS 路径。

连步骤：拖拽连接输入和输出步骤，设置字段映射。

运行转换：保存后运行，完成本地文件到 HDFS 的加载。

数据脱敏的核心原则是 “去敏感 + 保可用”，具体包括：
保数据特征：脱敏后仍保留原数据格式（如身份证的区域、日期等结构）。
保数据一致性：不同字段间的逻辑关系不变（如年龄和身份证生日需匹配）。
保业务规则关联：主外键、业务语义等关联关系不被破坏（如账户类数据的关联信息要一致）。
保多次脱敏一致：同一数据多次 / 多系统脱敏结果相同，保障业务连续性。

简述 Kettle 中作业的概念。
作业由一个或多个作业项（作业或转换）组成。所有的作业项是以某种自定义的顺序串行执行的。作业项之间可以传递一个包含了数据行的结果对象。当一个作业项执行行完成后，再传递结果对象给下一个作业项。作业里可以有循环。

在数据脱敏中，简述如何保持原有的数据待征。
数据脱敏前后必须保证数据特征的保持，例如：身份证号码由十七位数字本体码和一位校验码组成，分别为区域地址码（6 位）、出生日期（8 位）、顺序码（3 位）和校验码（1 位立）。那么身份证号码的脱敏规则就需要保证脱敏后依旧保持这些特征信息。

常见数据类型主要分 4 类：
文本：字符型数据（不能参与算术运算），存于文本文档，格式如 ASCII、TXT 等。
图片：图形 / 图像类数据，分点阵图（BMP、JPG）和矢量图（SWF、PSD）。
音频：数字化声音数据，存于音频文件，格式如 MP3、WAV 等。
视频：连续图像序列，存于视频文件，格式如 MP4、AVI 等。

xpath 语言的概念
XPath（XML Path Language）是用于在 XML/HTML 文档中查找信息的语言，能遍历文档的元素和属性；它提供超 100 个内置函数，可定位几乎所有节点，常用于网络爬虫中提取网页数据。

简述数据仓库的概念。
数据仓库是面向主题、集成、相对稳定、反映历史变化的数据集，用于支持管理决策：
面向主题：按决策关注的主题（如 “销售”）组织数据，而非事务流程。
集成：从分散的业务数据中抽取、加工、整合后存入。
相对稳定：以查询为主，数据不常更新。
反映历史变化：定时从数据源抽取数据，保留历史轨迹。

简述 CDC 的特性。
CDC（变化数据捕获）的核心特性有 3 点：

无宕机时间：可在业务系统运行时同步变化数据，不影响系统性能与服务。

保数据新颖性：实时 / 高频探测数据变化并分发，确保数据及时可用。

减系统开销：仅传输变化数据，资源消耗远低于批量 ETL，降低软硬件、人力成本。

简述 ETL 模式中全量同步的概念。

全量同步（又称 “全表删除插入方式”）是 ETL 的一种同步方式：每次同步前先清空目标表数据，再重新加载数据源的全部数据（将增量同步等价为全量抽取）。

它适合数据量小、全量抽取成本低于增量算法成本的场景；优点是不影响原系统结构、无需改业务程序、管理统一；缺点是 ETL 比对复杂、速度慢、性能差，无主键 / 唯一列时准确性低。

简述 Flume 每个组件的作用。

Flume 有 3 个核心组件，作用如下：

数据源（Source）：数据采集端，捕获数据并格式化为 Event（事件），推送到数据通道；常用类型如 Kafka、Taildir 等。

数据通道（Channel）：连接 Source 与 Sink 的缓冲区（队列），暂存 Event（可存内存 / 本地磁盘），直到 Sink 处理；常用类型如 Memory、File 等。

数据槽（Sink）：从 Channel 取出数据，存储到目标（如 HDFS、HBase）或提交到远程服务；常用类型如 HDFS、Kafka 等。

简述数据清洗与转换的主要作用

:数据清洗主要将不完整数据、错误数据、重复数据进行处理。数据转换包括:(1) 空值处理：可捕获字段空值，进行加载或替换为其他含义数据；

数据标准：统一元数据，统一标准字段，统一字段类型定义；

(3) 数据拆分：依据业务需求做数据拆分，如把身份证号拆分局成区划、出生日期、性别等；

(4) 数据验证：使用时间规则、业务规则、自定义规则等对数据进宁验证

(5) 数据替换：实现对无效数据、缺失数据的替换

；(6) 数据关联：对数据进行关联，保障数据完整性。